Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

Лабораторная работа №2 по дисциплине «Методы машинного обучения» на тему «Обработка признаков»

Выполнила: студентка группы ИУ5-21 М Базанова А.Г.

1. Лабораторная №2

Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

Задание:

- 1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- 2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
 - устранение пропусков в данных;
 - кодирование категориальных признаков;
 - нормализация числовых признаков.

2. Описание данных

- Date Дата наблюдений
- Location Название локации, в которой расположена метеорологическая станция
- MinTemp Минимальная температура в градусах цельсия
- МахТетр Максимальная температура в градусах цельсия
- Rainfall Количество осадков, зафиксированных за день в мм
- Evaporation Так называемое "pan evaporation" класса A (мм) за 24 часа до 9 утра
- Sunshine Число солнечных часов за день
- WindGustDir направление самого сильного порыва ветра за последние 24 часа
- WindGustSpeed скорость (км / ч) самого сильного порыва ветра за последние 24 часа
- WindDir9am направление ветра в 9 утра

```
[3]: import sklearn
from sklearn.model_selection import train_test_split
from sklearn.impute import SimpleImputer
import pandas as pd
import numpy as np
import seaborn as sns
import scipy.stats as stats
import matplotlib.pyplot as plt
```

```
[67]: data = pd.read_csv('weatherAUS.csv', parse_dates=['Date'])
```

```
[3]: data.head()
```

[3]:	Date	Location	${\tt MinTemp}$	MaxTemp	Rainfall	Evaporation	Sunshine	\
	0 2008-12-01	Albury	13.4	22.9	0.6	NaN	NaN	
	1 2008-12-02	Albury	7.4	25.1	0.0	NaN	NaN	
	2 2008-12-03	Albury	12.9	25.7	0.0	NaN	NaN	
	3 2008-12-04	Albury	9.2	28.0	0.0	NaN	NaN	
	4 2008-12-05	Albury	17.5	32.3	1.0	NaN	NaN	

	WindGustDir	WindGustSp	eed WindDi	r9am]	Humidity3p	m Pressure	9am \	
0	W	4	4.0	W		22.	0 100	7.7	
1	WNW	4	4.0	NNW		25.	0 101	0.6	
2	WSW	4	6.0	W	•••	30.	0 100	7.6	
3	NE	2	4.0	SE		16.		7.6	
4	W		1.0	ENE		33.		0.8	
	Pressure3pm	Cloud9am	Cloud3pm	Temp	9am	Temp3pm	RainToday	RISK_MM	\
0	1007.1	8.0	NaN	1	6.9	21.8	No	0.0	
1	1007.8	NaN	NaN	1	7.2	24.3	No	0.0	
2	1008.7	NaN	2.0	2	1.0	23.2	No	0.0	
3	1012.8	NaN	NaN	1	8.1	26.5	No	1.0	
4	1006.0	7.0	8.0	1	7.8	29.7	No	0.2	
	RainTomorrow	ī							
0	No)							
1	No)							
2	No)							
3	No)							
4	No)							

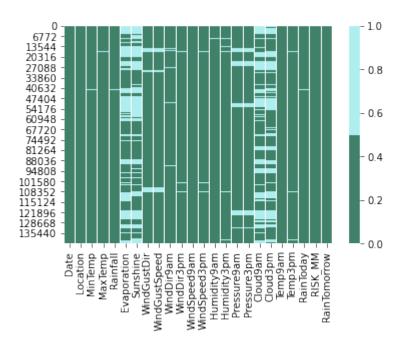
[5 rows x 24 columns]

2.1. Устранение пропусков в данных

Светлым цветом отметим пропущенные данные

```
[4]: cols = data.columns
  colours = ['#408169', '#AFEEEE']
  sns.heatmap(data[cols].isnull(), cmap=sns.color_palette(colours))
```

[4]: <matplotlib.axes._subplots.AxesSubplot at 0x7fe232f67f40>



[63]: data.info() <class 'pandas.core.frame.DataFrame'> RangeIndex: 142193 entries, 0 to 142192 Data columns (total 24 columns): Column Non-Null Count Dtype _____ _____ 0 Date 142193 non-null datetime64[ns] 142193 non-null object 1 Location 2 MinTemp 141556 non-null float64 3 141871 non-null float64 MaxTemp 4 Rainfall 140787 non-null float64 5 Evaporation 81350 non-null float64 6 Sunshine 74377 non-null float64 7 WindGustDir 132863 non-null object 8 WindGustSpeed 132923 non-null float64 9 WindDir9am 132180 non-null object 10 WindDir3pm 138415 non-null object WindSpeed9am 140845 non-null float64 12 WindSpeed3pm 139563 non-null float64 13 Humidity9am 140419 non-null float64 14 Humidity3pm 138583 non-null float64 15 Pressure9am 128179 non-null float64 16 Pressure3pm 128212 non-null float64 17 Cloud9am 88536 non-null float64 Cloud3pm 85099 non-null 18 float64 141289 non-null float64 19 Temp9am 20 Temp3pm 139467 non-null float64 21 RainToday 140787 non-null object 22 RISK MM 142193 non-null float64 23 RainTomorrow 142193 non-null object dtypes: datetime64[ns](1), float64(17), object(6)

Рассмотрим числовые колонки с пропущенными значениями

float64.

memory usage: 26.0+ MB

MaxTemp.

```
[68]: total count = data.shape[0]
      num cols = []
      for col in data.columns:
          temp_null_count = data[data[col].isnull()].shape[0]
          dt = str(data[col].dtype)
          if temp_null_count>0 and (dt=='float64' or dt=='int64'):
              num cols.append(col)
              temp_perc = round((temp_null_count / total_count) * 100.0, 2)
              print('
                          {}.
                                     {}.
                                                          {}, {}%.'.format(col, dt, ⊔
       →temp null count, temp perc))
          MinTemp.
                          float64.
                                                    637, 0.45%.
```

322, 0.23%.

Rainfall.	float64.	1406, 0.99%.
Evaporation.	float64.	60843,
42.79%.		
Sunshine.	float64.	67816, 47.69%.
${\tt WindGustSpeed}.$	float64.	9270,
6.52%.		
WindSpeed9am.	float64.	1348,
0.95%.		
WindSpeed3pm.	float64.	2630,
1.85%.		
Humidity9am.	float64.	1774, 1.25%.
Humidity3pm.	float64.	3610, 2.54%.
Pressure9am.	float64.	14014,
9.86%.		
Pressure3pm.	float64.	13981,
9.83%.		
Cloud9am.	float64.	53657, 37.74%.
Cloud3pm.	float64.	57094, 40.15%.
Temp9am.	float64.	904, 0.64%.
Temp3pm.	float64.	2726, 1.92%.

Фильтр по колонкам с пропущенными значениями

[6]:	<pre>data_num = data[num_cols]</pre>
	data_num

[6]:		MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine W	indGustSpeed	\
	0	13.4	22.9	0.6	NaN	NaN	44.0	
	1	7.4	25.1	0.0	NaN	NaN	44.0	
	2	12.9	25.7	0.0	NaN	NaN	46.0	
	3	9.2	28.0	0.0	NaN	NaN	24.0	
	4	17.5	32.3	1.0	NaN	NaN	41.0	
	•••	•••	•••			•••		
	142188	3.5	21.8	0.0	NaN	NaN	31.0	
	142189	2.8	23.4	0.0	NaN	NaN	31.0	
	142190	3.6	25.3	0.0	NaN	NaN	22.0	
	142191	5.4	26.9	0.0	NaN	NaN	37.0	
	142192	7.8	27.0	0.0	NaN	NaN	28.0	
		WindSpee	d9am Wir	ndSpeed3pm	Humidity9am	Humidity3pm	Pressure9am	\
	0		20.0	24.0	71.0	22.0	1007.7	
	1		4.0	22.0	44.0	25.0	1010.6	
	2		19.0	26.0	38.0	30.0	1007.6	
	3		11.0	9.0	45.0	16.0		
	4		7.0	20.0	82.0	33.0	1010.8	
	•••	•••					•••	
	142188		15.0	13.0	59.0	27.0	1024.7	
	142189		13.0	11.0	51.0	24.0	1024.6	
	142190		13.0	9.0	56.0	21.0	1023.5	
	142191		9.0	9.0	53.0	24.0	1021.0	
	142192		13.0	7.0	51.0	24.0	1019.4	

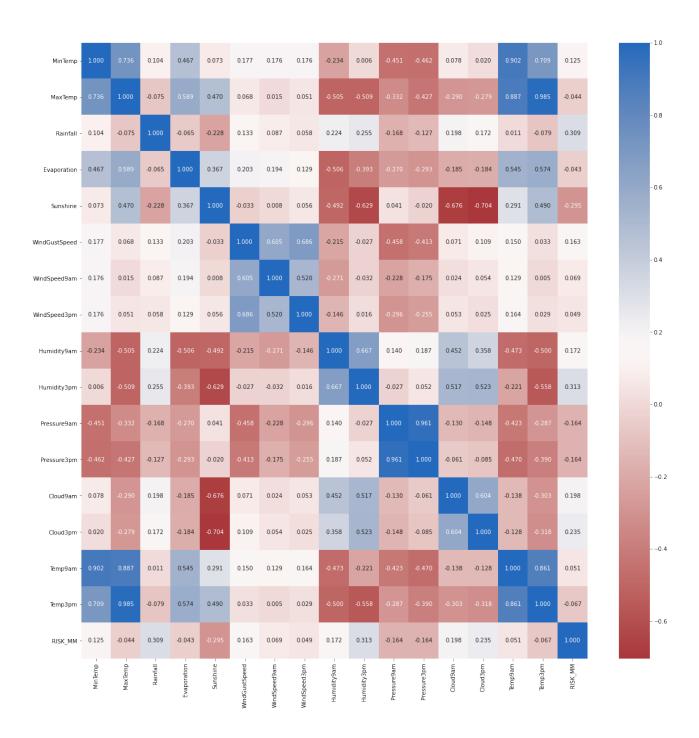
	Pressure3pm	Cloud9am	Cloud3pm	Temp9am	Temp3pm
0	1007.1	8.0	NaN	16.9	21.8
1	1007.8	NaN	NaN	17.2	24.3
2	1008.7	NaN	2.0	21.0	23.2
3	1012.8	NaN	NaN	18.1	26.5
4	1006.0	7.0	8.0	17.8	29.7
•••	•••	•••		•••	
142188	1021.2	NaN	NaN	9.4	20.9
142189	1020.3	NaN	NaN	10.1	22.4
142190	1019.1	NaN	NaN	10.9	24.5
142191	1016.8	NaN	NaN	12.5	26.1
142192	1016.5	3.0	2.0	15.1	26.0

[142193 rows x 16 columns]

```
[30]: import sys
import numpy
numpy.set_printoptions(threshold=sys.maxsize)

corrmat = data.corr()
plt.figure(figsize=(20,20))
sns.heatmap(corrmat, annot=True, fmt='.3f', cmap="vlag_r")
```

[30]: <matplotlib.axes._subplots.AxesSubplot at 0x7fe22c411130>



В столбце Evaporation 42.79% пропущенных данных, и его корреляция с целевым признаком низкая, так что легче всего этот столбец удалить.

```
[69]: data = data.drop(['Evaporation'], axis = 1)
num_cols.remove('Evaporation')
```

Все распределения, кроме Sunshine, одномодальные, так что будем использовать для заполнения пропусков моду. Для Sunshine медиану.

```
[70]: data['Sunshine'] = data['Sunshine'].fillna(data.median(numeric_only=True))

[71]: data['Humidity9am'] = data['Humidity9am'].fillna(data['Humidity9am'].mode())
```

```
Рассмотрим пропуски в категориальных данных
[21]: cat cols = []
      for col in data.columns:
           temp_null_count = data[data[col].isnull()].shape[0]
           dt = str(data[col].dtype)
           if temp null count>0 and (dt=='object'):
               cat_cols.append(col)
              temp_perc = round((temp_null_count / total_count) * 100.0, 2)
                                                         {}, {}%.'.format(col, dt, ⊔
                        {}.
        →temp_null_count, temp_perc))
           WindGustDir.
                                                       9330, 6.56%.
                               object.
                                                      10013, 7.04%.
           WindDir9am.
                              object.
           WindDir3pm.
                                                      3778, 2.66%.
                              object.
           RainToday.
                                                     1406, 0.99%.
                             object.
[75]: for col in data[cat_cols]:
                    {}. {}'.format(col, data[col].unique()))
           print('
           WindGustDir. ['W' 'WNW' 'WSW' 'NE' 'NNW' 'N' 'NNE' 'SW' 'ENE' 'SSE' 'S'
      'NW' 'SE' 'ESE'
       nan 'E' 'SSW']
           WindDir9am. ['W' 'NNW' 'SE' 'ENE' 'SW' 'SSE' 'S' 'NE' nan 'SSW' 'N'
      'WSW' 'ESE' 'E'
       'NW' 'WNW' 'NNE']
           WindDir3pm. ['WNW' 'WSW' 'E' 'NW' 'W' 'SSE' 'ESE' 'ENE' 'NNW' 'SSW' 'SW'
      'SE' 'N' 'S'
       'NNE' nan 'NE']
           RainToday. ['No' 'Yes' nan]
[73]: data[:] = SimpleImputer(missing_values=np.nan, strategy='most_frequent').
       →fit_transform(data)
[110]: data.info()
      <class 'pandas.core.frame.DataFrame'>
      RangeIndex: 142193 entries, 0 to 142192
      Data columns (total 23 columns):
           Column
                          Non-Null Count
                                           Dtype
      ____
       0
                          142193 non-null datetime64[ns]
           Date
                          142193 non-null object
       1
           Location
       2
                          142193 non-null float64
          MinTemp
                          142193 non-null float64
           MaxTemp
          Rainfall
                         142193 non-null float64
           Sunshine
                         142193 non-null float64
       5
           WindGustDir 142193 non-null object
       6
       7
           WindGustSpeed 142193 non-null float64
```

[72]: data = data.fillna(data.mode())

```
8
    WindDir9am
                    142193 non-null
                                    object
9
    WindDir3pm
                    142193 non-null
                                    object
10
    WindSpeed9am
                    142193 non-null
                                    float64
    WindSpeed3pm
11
                    142193 non-null
                                    float64
12
    Humidity9am
                    142193 non-null
                                    float64
13
    Humidity3pm
                    142193 non-null
                                    float64
    Pressure9am
                                    float64
14
                    142193 non-null
15 Pressure3pm
                    142193 non-null float64
16
    Cloud9am
                    142193 non-null float64
17
    Cloud3pm
                    142193 non-null float64
18
    Temp9am
                   142193 non-null float64
                    142193 non-null float64
19
    Temp3pm
20
    RainToday
                    142193 non-null object
21
    RISK MM
                    142193 non-null
                                    float64
22 RainTomorrow
                   142193 non-null
                                    object
dtypes: datetime64[ns](1), float64(16), object(6)
```

memory usage: 25.0+ MB

[42]: data.isnull().sum()

0 [42]: Date 0 Location MinTemp 0 0 MaxTemp Rainfall 0 Sunshine 0 WindGustDir 0 WindGustSpeed 0 WindDir9am 0 WindDir3pm 0 WindSpeed9am 0 WindSpeed3pm 0 0 Humidity9am Humidity3pm 0 Pressure9am 0 Pressure3pm 0 Cloud9am 0 Cloud3pm 0 Temp9am 0 Temp3pm 0 RainToday 0 RISK MM 0 RainTomorrow 0 dtype: int64

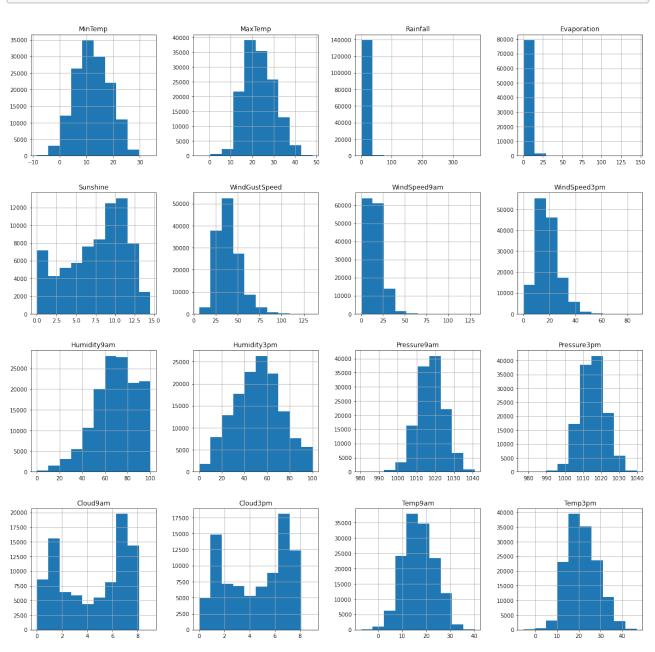
2.2. Кодирование категориальных признаков

```
data['RainTomorrow'] = data['RainTomorrow'].apply(lambda x: 1 if x == 'Yes',
        \rightarrowelse 0)
[136]: data['Location'].unique()
[136]: array(['Albury', 'BadgerysCreek', 'Cobar', 'CoffsHarbour', 'Moree',
              'Newcastle', 'NorahHead', 'NorfolkIsland', 'Penrith', 'Richmond',
              'Sydney', 'SydneyAirport', 'WaggaWagga', 'Williamtown',
              'Wollongong', 'Canberra', 'Tuggeranong', 'MountGinini', 'Ballarat',
              'Bendigo', 'Sale', 'MelbourneAirport', 'Melbourne', 'Mildura',
              'Nhil', 'Portland', 'Watsonia', 'Dartmoor', 'Brisbane', 'Cairns',
              'GoldCoast', 'Townsville', 'Adelaide', 'MountGambier', 'Nuriootpa',
              'Woomera', 'Albany', 'Witchcliffe', 'PearceRAAF', 'PerthAirport',
              'Perth', 'SalmonGums', 'Walpole', 'Hobart', 'Launceston',
              'AliceSprings', 'Darwin', 'Katherine', 'Uluru'], dtype=object)
         Слишком много категорий Location для OneHotEncoder
[75]: from sklearn.preprocessing import LabelEncoder
       le = LabelEncoder()
       data['Location'] = le.fit transform(data['Location'])
[76]: categorical = ['WindDir3pm', 'WindDir9am', 'WindGustDir']
       data = pd.concat([data, pd.get_dummies(data[categorical],__
        →columns=categorical, drop_first=True)],axis=1)
       data.drop(categorical, axis=1, inplace=True)
[11]: data.shape
[11]: (142193, 65)
      2.3. Нормализация числовых признаков
[77]: data[num cols] = data[data[num cols] > 0][num cols]
[79]: def diagnostic_plots(df, variable):
          plt.figure(figsize=(15,6))
           plt.subplot(1, 2, 1)
           df[variable].hist(bins=30)
           ## Q-Q plot
           plt.subplot(1, 2, 2)
           stats.probplot(df[variable], dist="norm", plot=plt)
           plt.show()
```

[74]: data['RainToday'] = data['RainToday'].apply(lambda x: 1 if x == 'Yes' else_

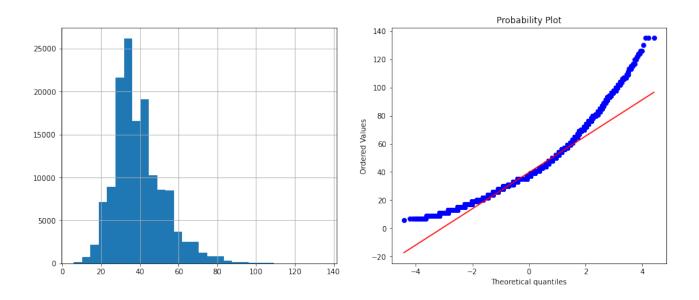
```
[128]: def diagnostic_plots_data(df):
    plt.figure(figsize=(15,6))
    #
    plt.subplot(1, 2, 1)
    df.hist(bins=30)
    ## Q-Q plot
    plt.subplot(1, 2, 2)
    stats.probplot(df, dist="norm", plot=plt)
    plt.show()
```

[59]: data_num.hist(figsize=(20,20)) plt.show()

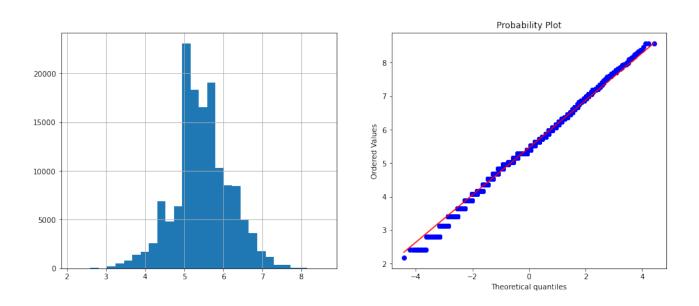


```
[138]: diagnostic_plots(data, 'WindGustSpeed')

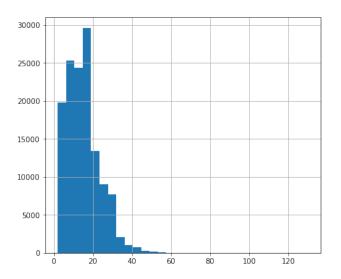
data['WindGustSpeed_boxcox'], param = stats.boxcox(data['WindGustSpeed'])
print(' = {}'.format(param))
diagnostic_plots(data, 'WindGustSpeed_boxcox')
```

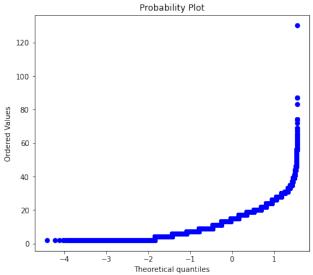


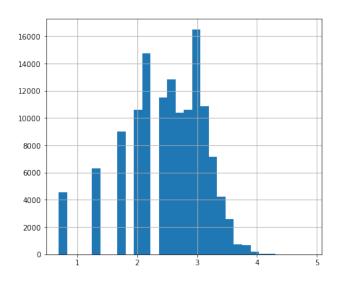
= 0.21000467599892894

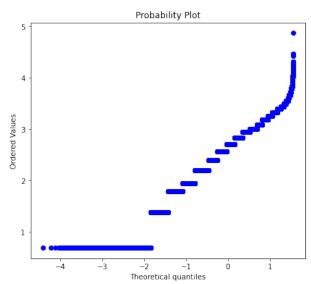


```
[139]: diagnostic_plots(data, 'WindSpeed9am')
diagnostic_plots_data( np.log(data['WindSpeed9am']) )
```

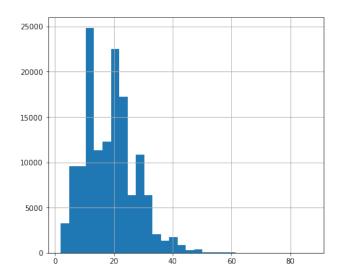


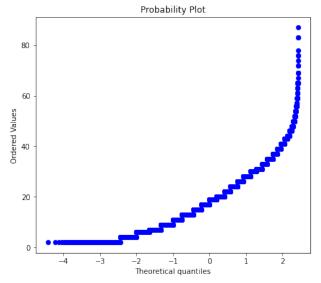


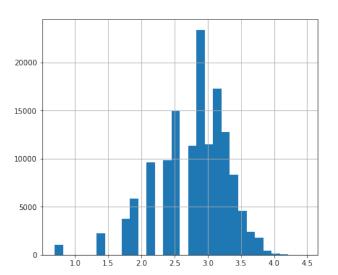


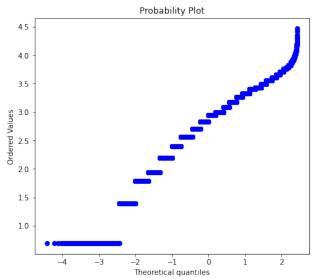


```
[167]: diagnostic_plots(data, 'WindSpeed3pm')
    diagnostic_plots_data( np.log( (data['WindSpeed3pm']) ) )
```









```
[81]: data['WindSpeed9am'] = np.log( (data['WindSpeed9am']) )
  data['WindSpeed3pm'] = np.log( (data['WindSpeed3pm']) )
  data['WindGustSpeed'], param = stats.boxcox(data['WindGustSpeed'])
```